

Kapitel 1: Bayes-Netze



Bayes-Netze

Ausgangspunkt:

- Wahrscheinlichkeitsverteilungen über Welten sind geeignet, um unsicheres Wissen zu repräsentieren
- Eine naive Repräsentation als Liste von Wahrscheinlichkeiten ist
 - exponentiell groß, also mit vertretbarem Aufwand weder anzugeben noch zu speichern
 - auch für Experten wegen exotischer Sonderfälle nur schwer zu konstruieren
- Unabhängigkeit erlaubt kompakte Repräsentation und bringt Struktur in die Menge der Ereignisse

Übersicht Kapitel 1

- Kapitel 1.1: Mehr zu Unabhängigkeit
- Kapitel 1.2: Bayes-Netze
- Kapitel 1.3: Graphoid Axiome
- Kapitel 1.4: d-Separation



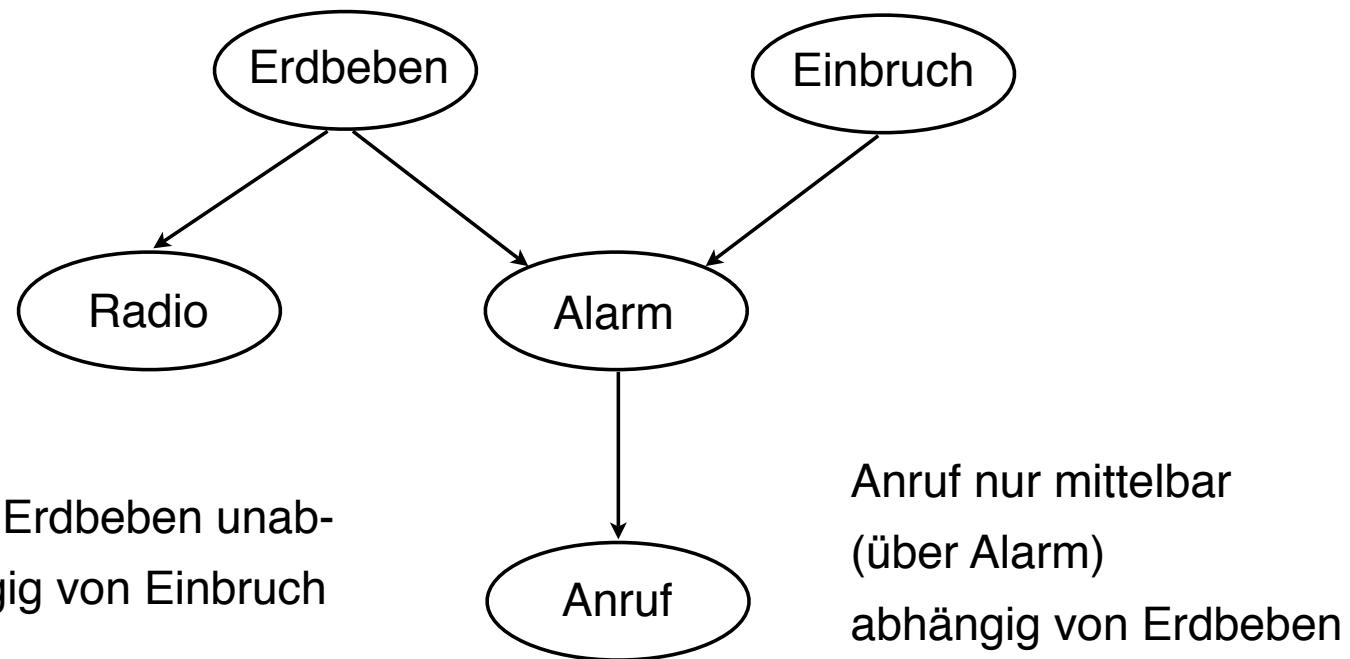
Bayes-Netze

Kapitel 1.1: Mehr zu Unabhängigkeit



Bayes-Netze

Bayes-Netze verwenden Graph, um Unabhängigkeiten zu spezifizieren:

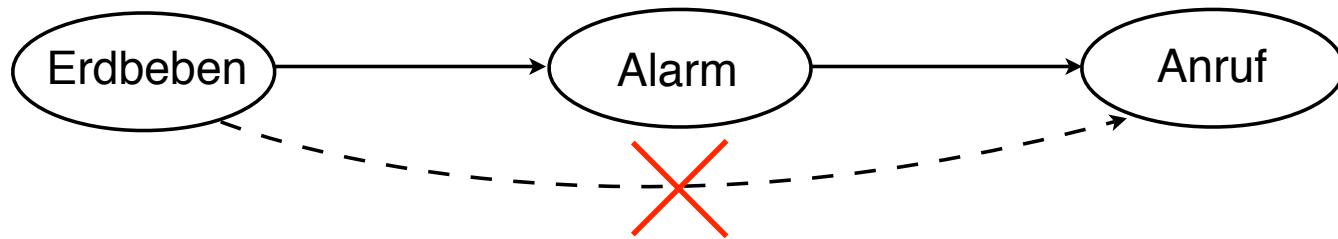


Basierend auf einer solchen Struktur kann man dann Verteilungen in (meist) kompakter Weise beschreiben

Unabhängigkeit

Wir werden sehen: je weniger Pfeile im Unabhängigkeits-Graph, desto kompakter kann eine Verteilung für diesen Graph repräsentiert werden.

Mittelbare (Un)Abhängigkeiten wichtig zur Reduktion der Kantenzahl:



Formal beschreiben wir das mittels **konditionaler Unabhängigkeit**

Zentrale Beobachtung: Genau wie Wkten ist auch Unabhängigkeit von **dynamischer Natur**, kann von **neuer Evidenz** sowohl zerstört als auch hergestellt werden

Unabhängigkeit

Einbruch ist unabhängig von Erdbeben:

$$\Pr(\text{Erdbeben}) = .1$$

Welt	Erdbeben	Einbruch	Alarm	$\Pr(\cdot)$	$\Pr(\cdot \text{Erdbeben})$
ω_1	false	false	false	.7128	0
ω_2	false	false	true	.0072	0
ω_3	false	true	false	.0180	.1800
ω_4	false	true	true	.1620	0
ω_5	true	false	false	.0240	.2400
ω_6	true	false	true	.0560	.5600
ω_7	true	true	false	.0010	.0100
ω_8	true	true	true	.0190	.1900

$$\Pr(\text{Einbruch}) = .2$$

$$\Pr(\text{Einbruch}|\text{Erdbeben}) = .2$$



Unabhängigkeit

Nach Konditionierung mit Alarm ist das nicht mehr der Fall:

$$\Pr(\text{Einbruch}|\text{Alarm}) \approx .741$$

$$\Pr(\text{Einbruch}|\text{Alarm} \wedge \text{Erdbeben}) \approx .253$$



erst mit Alarm konditionieren, dann mit Erdbeben
(oder andersrum, was äquivalent ist)

Macht intuitiv Sinn:

- Einbruch und Erdbeben sind **konkurrierende Ursachen** für Alarm
- wenn wir lernen, dass eine davon eingetreten ist, nehmen wir an,
dass die andere wohl nicht (zusätzlicher) Auslöser für den Alarm ist

Unabhängigkeit

Unabhängigkeit kann auch durch Konditionierung **entstehen**:

Angenommen wir haben zwei fehleranfällige Temperatursensoren, interessieren uns dafür, ob Temperatur normal oder extrem ist

Variablen: TNormal, S1Normal, S2Normal

Eingangs könnten wir haben:

$$\Pr(\text{TNormal}) = .80$$

$$\Pr(\text{S1Normal}) = .76$$

$$\Pr(\text{S2Normal}) = .68$$

Mit Evidenz TNormal **verschwindet** diese Abhängigkeit:

$$\Pr(\text{S2Normal}|\text{TNormal}) = .80$$

$$\Pr(\text{S2Normal}|\text{TNormal} \wedge \text{S1Normal}) = .80$$

Intuitiv sollte S2Normal abhängig sein von S1Normal:

$$\Pr(\text{S2Normal}|\text{S1Normal}) \approx .768$$



Konditionale Unabhängigkeit

Konditionale Unabhängigkeit von φ und ψ gegeben ϑ :
 φ ist unabhängig von ψ nach Konditionierung mit ϑ

Definition konditional unabhängig

Seien φ, ψ, ϑ aussagenlogische Formeln. Wir nennen φ *unabhängig von ψ gegeben ϑ* wenn $\Pr(\varphi|\psi \wedge \vartheta) = \Pr(\varphi|\vartheta)$ oder $\Pr(\psi \wedge \vartheta) = 0$.

schreiben wir statt “ $\Pr((\varphi|\psi)|\vartheta)$ ”

Äquivalent ist: $\Pr(\varphi \wedge \psi|\vartheta) = \Pr(\varphi|\vartheta) \cdot \Pr(\psi|\vartheta)$

Dies zeigt auch folgende Symmetrie:

φ ist unabhängig von ψ gegeben ϑ gdw. ψ ist unabhängig von φ gegeben ϑ .

Unabhängigkeit von Variablenmengen

Wir wollen in der Lage sein, zu beschreiben, dass es innerhalb einer Menge von Variablen **keinerlei (unkonditionale) Abhängigkeiten** gibt

Bereits gesehen: paarweise Unabhängigkeit ist nicht ausreichend

Definition $I(X, Z, Y)$

Seien X, Y, Z disjunkte Mengen von Variablen. Dann ist X *unabhängig von Y gegeben Z* , geschrieben $I_{\text{Pr}}(X, Z, Y)$ wenn folgendes gilt:

für alle $\varphi_{X'} \in \text{Inst}(X)$, $\varphi_{Y'} \in \text{Inst}(Y)$, $\varphi_{Z'} \in \text{Inst}(Z)$:

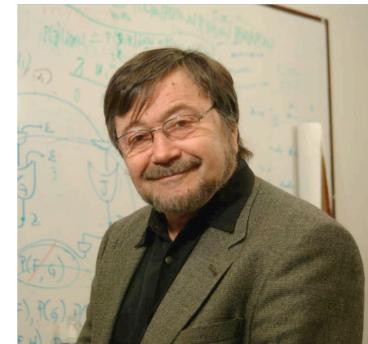
$\varphi_{X'}$ ist unabhängig von $\varphi_{Y'}$ gegeben $\varphi_{Z'}$.



Wenn X (oder Y oder Z) nur ein Element hat, lassen wir Mengenklammern weg, z.B. $I_{\text{Pr}}(x, y, \{z_1, z_2\})$ statt $I_{\text{Pr}}(\{x\}, \{y\}, \{z_1, z_2\})$.

Bayes-Netze

Kapitel 1.2: Bayes-Netze



Bayes-Netze

Ein Bayes-Netz besteht aus

- gerichtetem azyklischen Graph (DAG), der Unabhängigkeiten beschreibt
- Annotation dieses Graphen mit Wahrscheinlichkeiten

deren Kombination genau eine Verteilung definiert.

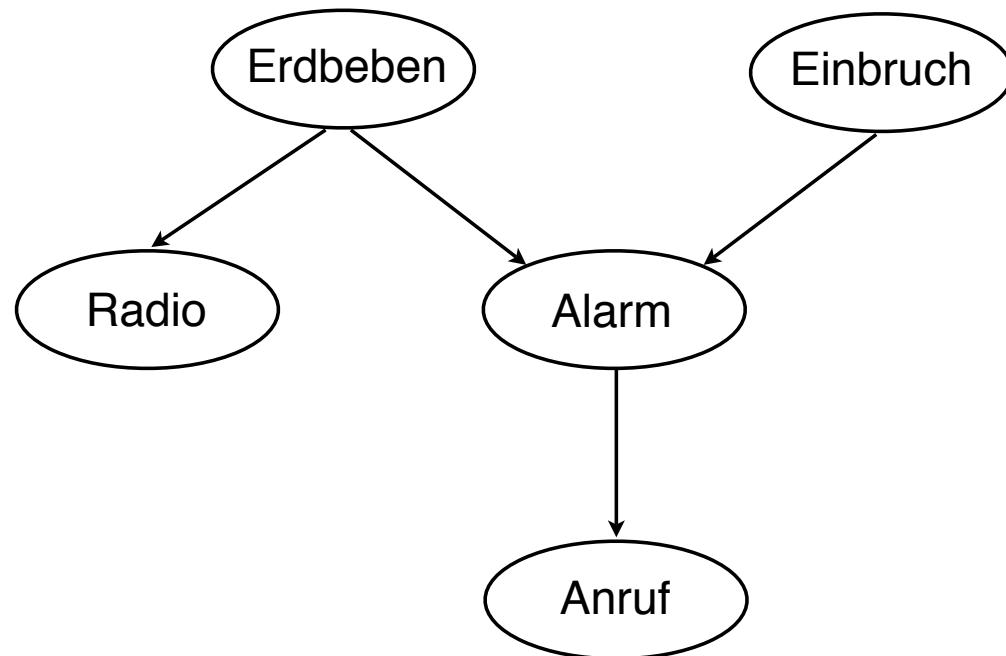
Notation für Graphen: für jede Variable x ist

$\text{Parents}(x)$ die Menge der Knoten y mit direkter Kante von y nach x

$\text{Descendants}(x)$ die Menge der Knoten y mit einer Kantenfolge beliebiger Länge ≥ 1 von x nach y

$\text{Non-Descendants}(x)$ sind alle Variablen außer x , $\text{Parents}(x)$ und $\text{Descendants}(x)$

Bayes-Netze

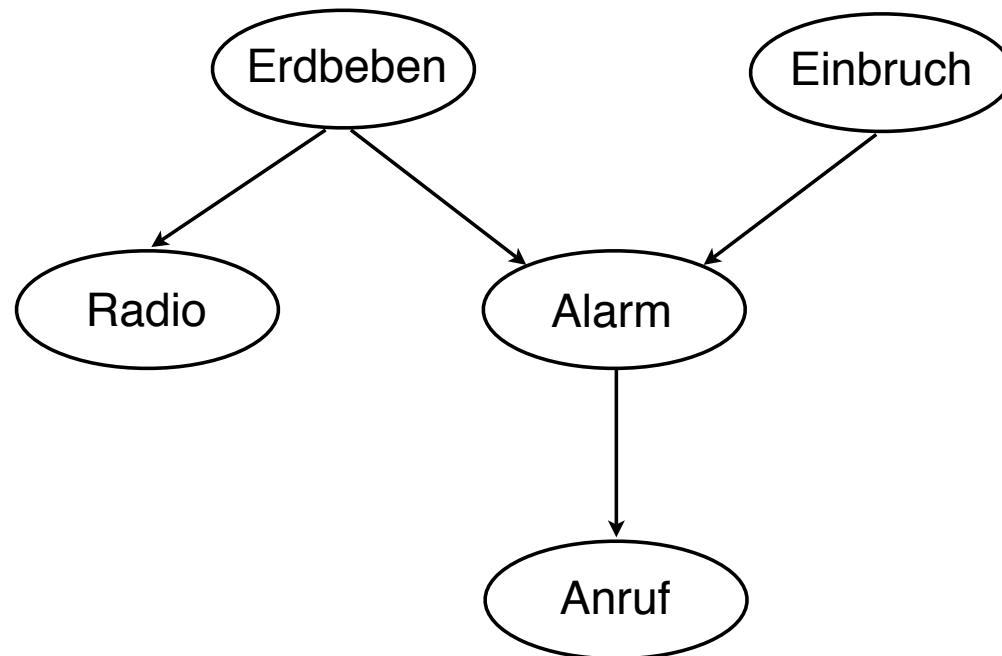


$\text{Parents}(\text{Erdbeben}) = \emptyset$

$\text{Parents}(\text{Alarm}) = \{\text{Erdbeben}, \text{Einbruch}\}$

$\text{Parents}(\text{Anruf}) = \{\text{Alarm}\}$

Bayes-Netze



$\text{Non-Descendants}(\text{Erdbeben}) = \{\text{Einbruch}\}$

$\text{Non-Descendants}(\text{Alarm}) = \{\text{Erdbeben}, \text{Einbruch}, \text{Radio}\}$

$\text{Non-Descendants}(\text{Anruf}) = \{\text{Erdbeben}, \text{Einbruch}, \text{Radio}, \text{Alarm}\}$

Bayes-Netze

Ein DAG repräsentiert die folgenden Unabhängigkeiten:

$$I(x, \text{Parents}(x), \text{Non-Descendants}(x)) \quad \text{für jeden Knoten } x$$

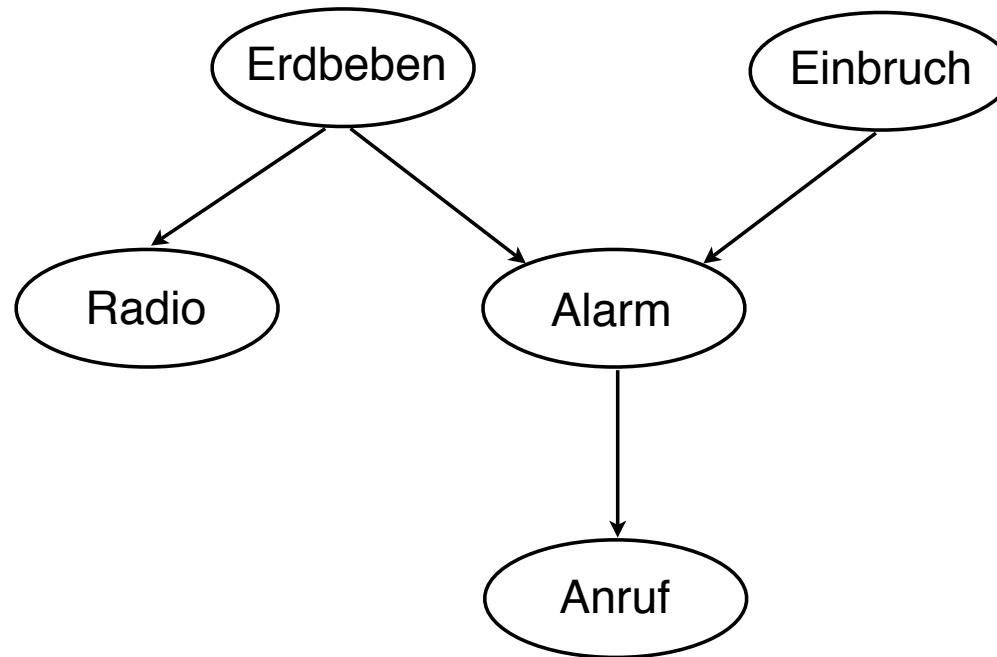
In Worten:

jedes Ereignis x ist unabhängig von $\text{Non-Descendants}(x)$ gegeben $\text{Parents}(x)$.

Idee dahinter:

- Der Übersichtlichkeit halber lesen wir Graph **von oben nach unten** blenden alle Descendants erstmal aus; darum **Non-Descendants**
- Abhängigkeiten von anderen Knoten kann es nur nur **mittelbar** über die Parents geben
- **aus den Wkten von Parents(x) ergibt sich also die Wkt von x ,** die Wkt anderer Knoten spielt dann keine Rolle mehr

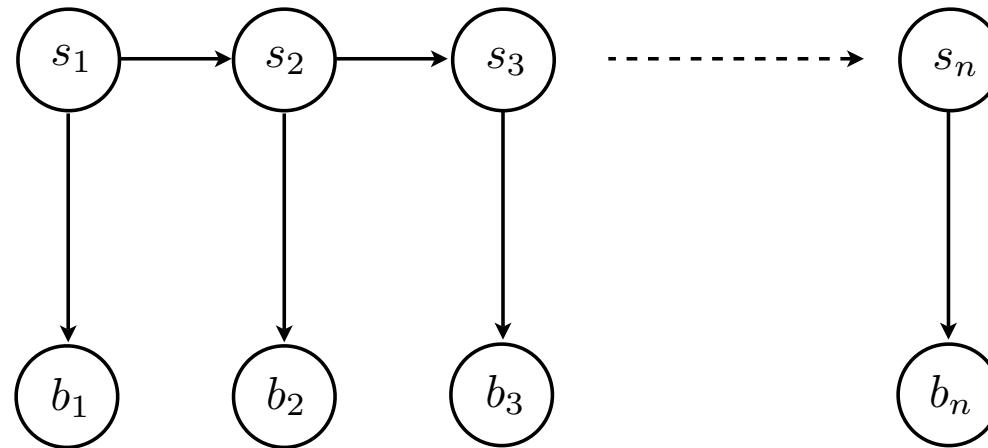
Bayes-Netze



Für einen DAG G bezeichnen wir die Menge aller Statements $I(x, \text{Parents}(x), \text{Non-Descendants}(x))$ mit $\text{Unabh}(G)$.

Bayes-Netze

Folgender DAG heisst Hidden Markov Model (HMM):



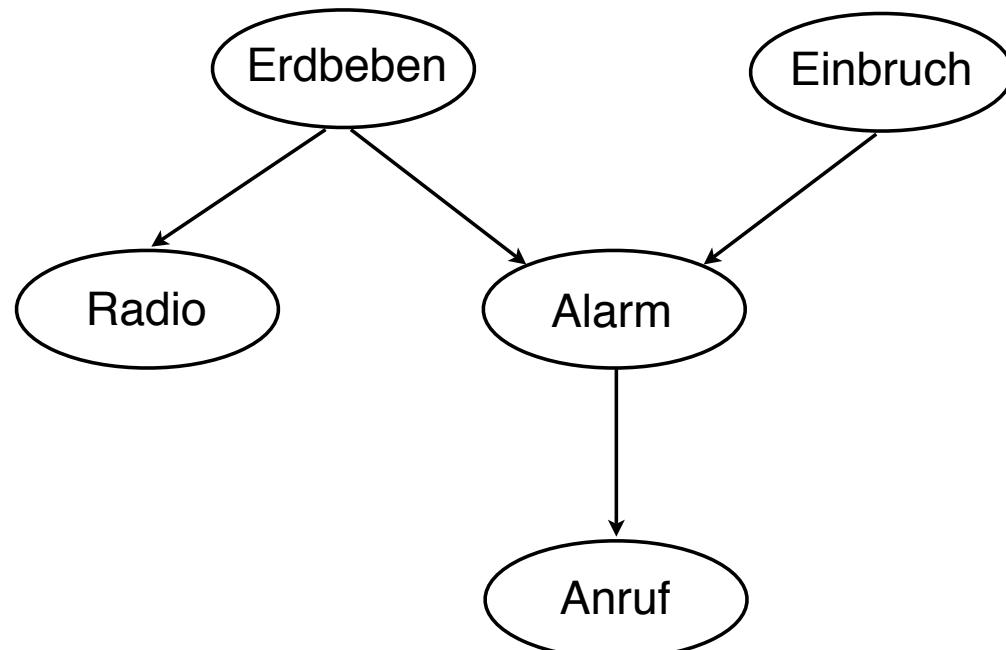
Das HMM repräsentiert die Evolution eines Systems von Zeitpunkt 1 bis n

Dabei bezeichnet s_i den tatsächlichen Zustand des Systems
und b_i der Wert eines Sensors, der das System beobachtet
(alle Variablen mehrwertig)

Für jedes s_i ergibt sich $I(s_i, s_{i-1}, \{s_1, \dots, s_{i-2}, b_1, \dots, b_{i-1}\})$.

Bayes-Netze

Jede Variable x annotiert mit **konditionaler Wahrscheinlichkeitstabelle (KWT)**: für jede Belegung von $\text{Parents}(x)$ eine Verteilung über die Werte von x .



Zusammen mit den Unabhängigkeiten in $\text{Unabh}(G)$ definieren die KWTen eine **eindeutige** Verteilung Pr über allen Variablen in G

Bayes-Netze

Die Größe einer KWT ist natürlich im Prinzip **immernoch exponentiell**

Allerdings nur in der Anzahl der Parents (meist wenige)
statt in der Anzahl **aller** Variablen (meist viele)

Im konkreten Fall des Einbruch-Erdbeben-Alarm-DAGs:

- alle KWTs zusammengenommen enthalten 10 Wkten
- es gibt 5 Variablen, also 32 Belegungen und bei naiver Repräsentation sind demnach 32 Wktenenzugeben

Im folgenden: Formale Definition der Syntax und Semantik

Bayes-Netze

Definition Bayes-Netz

Ein *Bayes-Netz (BN)* ist ein Paar $N = (G, \Theta)$ wobei

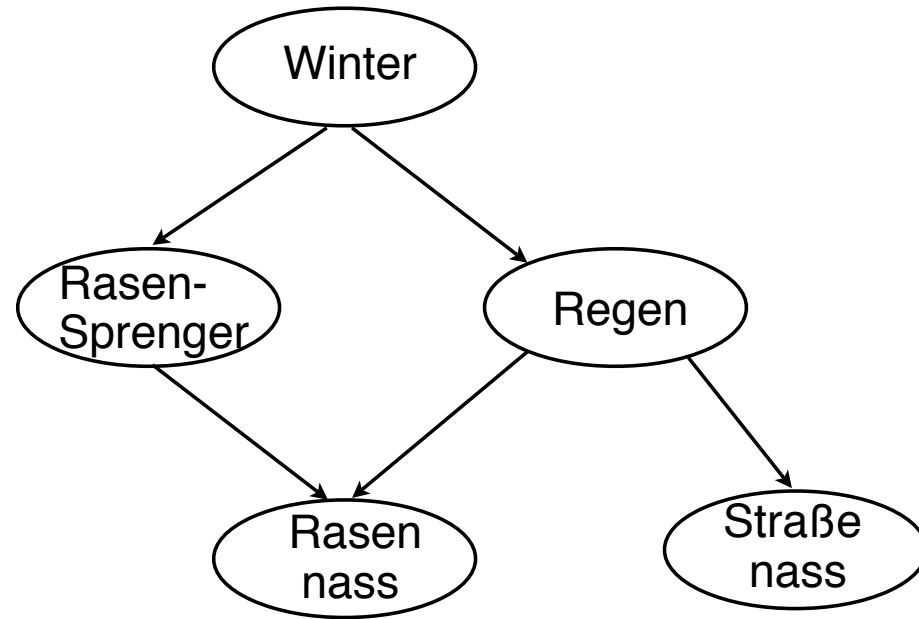
- G die *Struktur* von N ist:
gerichteter azyklischer Graph, dessen Knoten wir Variablen nennen
- Θ die *Parametrisierung* von N ist:
Eine konditionale Wahrscheinlichkeitstabelle für jede Variable

Wir bezeichnen mit

- $\Theta_{x|P}$ die KWT für die Variable x mit $\text{Parents}(x) = P$
- $\theta_{x=v|\omega}$ die Wkt für $x = v$ in der Zeile von $\Theta_{x|P}$ für Belegung ω
(z.B. $\theta_{\text{Alarm}=an|Erdbeben \wedge \neg \text{Einbruch}}$)

Bayes-Netze

Ein weiteres Beispiel:

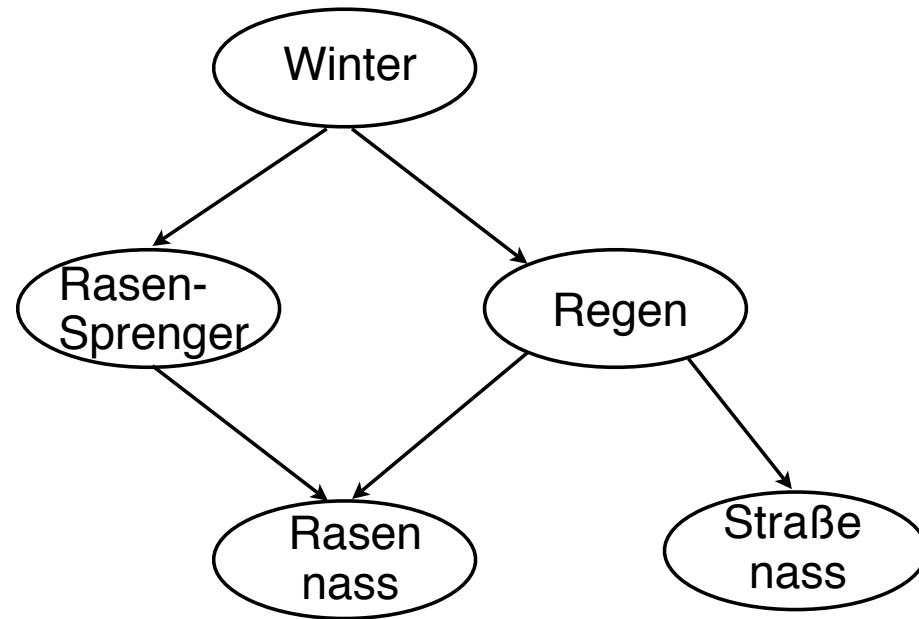


$\Theta_{\text{Winter}|\emptyset}$ ist

	Winter = true	Winter = false
	.6	.4

Bayes-Netze

Ein weiteres Beispiel:

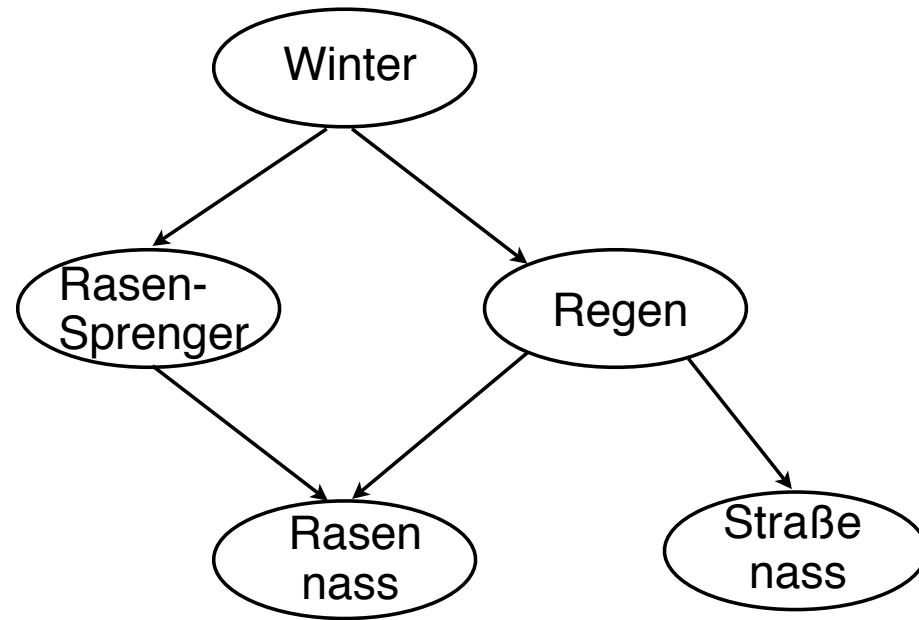


$\Theta_{\text{Rasensprenger}|\text{Winter}}$ ist

Winter	$\text{Rasensprenger} = \text{true}$	$\text{Rasensprenger} = \text{false}$
t	.2	.8
f	.75	.25

Bayes-Netze

Ein weiteres Beispiel:

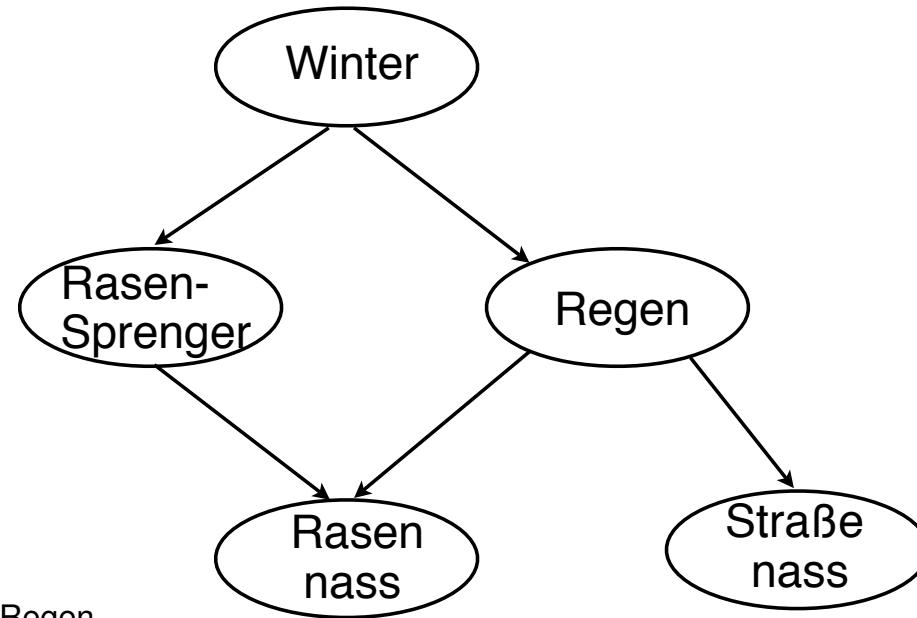


$\Theta_{\text{Regen}|\text{Winter}}$ ist

Winter	Regen	\neg Regen
t	.8	.2
f	.1	.9

Bayes-Netze

Ein weiteres Beispiel:

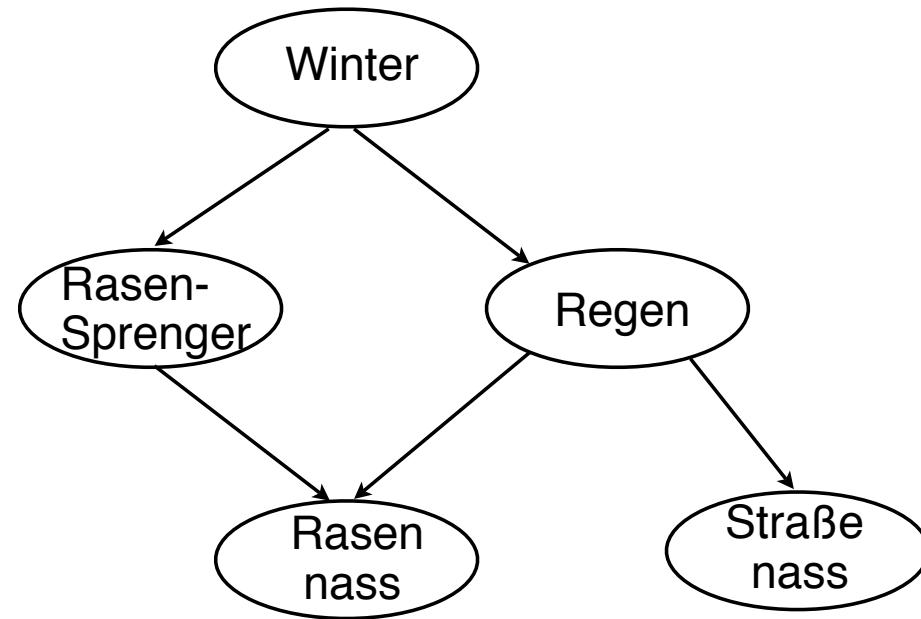


$\Theta_{\text{Rasen nass} | \text{Rasensprenger, Regen}}$

ist	Rasensprenger	Regen	Rasennass	\neg Rasennass
	t	t	.95	.05
	t	f	.9	.1
	f	t	.8	.2
	f	f	0	1

Bayes-Netze

Ein weiteres Beispiel:

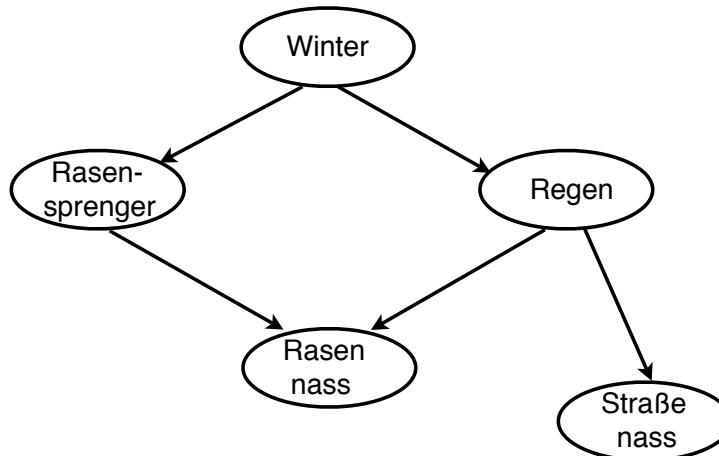


$\Theta_{\text{Strasse nass}|\text{Regen}}$ ist

	Regen	Strassenass	\neg Strassenass
t		.7	.3
f		0	1

Bayes-Netze: Semantik

Die durch ein BN repräsentierte Verteilung illustrieren wir zunächst anhand eines Beispiels



Betrachte Belegung

$$\omega(W) = \text{true}$$

$$\omega(RS) = \text{false}$$

$$\omega(R) = \text{true}$$

$$\omega(Rn) = \text{true}$$

$$\omega(Sn) = \text{false}$$

$\Theta_{W \emptyset}$	W	$\neg W$
	.6	.4

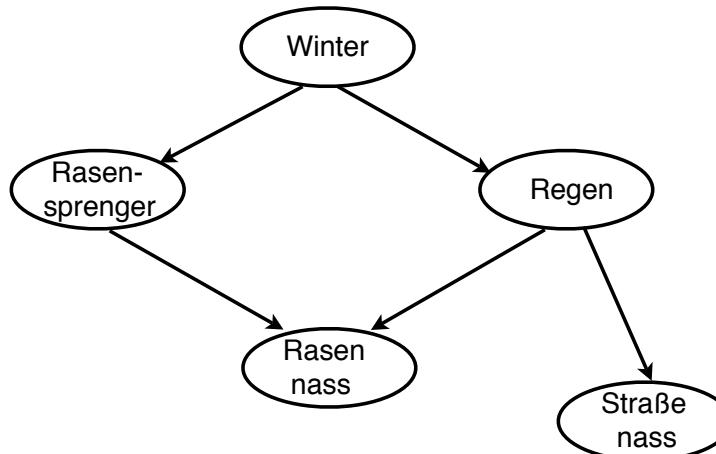
$$\Pr(W) = .6$$

$\Theta_{RS W}$	W	RS	$\neg RS$
	t	.2	.8
	f	.75	.25

$$\Pr(W \wedge \neg RS) = .6 \cdot .8 = .48$$

Bayes-Netze: Semantik

Die durch ein BN repräsentierte Verteilung illustrieren wir zunächst anhand eines Beispiels



Betrachte Belegung

$$\begin{array}{ll} \omega(W) & = \text{true} \\ \omega(RS) & = \text{false} \\ \omega(R) & = \text{true} \\ \omega(Rn) & = \text{true} \\ \omega(Sn) & = \text{false} \end{array}$$

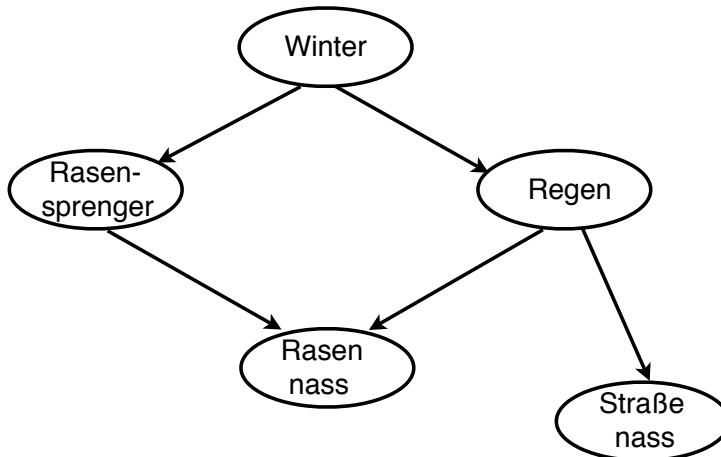
$$\Pr(W \wedge \neg RS) = .48$$

$\Theta_{R W}$	W	R	$\neg R$
	t	.8	.2
f	.1	.9	

$$\Pr(W \wedge \neg RS \wedge R) = .48 \cdot .8 = .384$$

Bayes-Netze: Semantik

Die durch ein BN repräsentierte Verteilung illustrieren wir zunächst anhand eines Beispiels



Betrachte Belegung

$$\begin{array}{ll} \omega(W) & = \text{true} \\ \omega(RS) & = \text{false} \\ \omega(R) & = \text{true} \\ \omega(Rn) & = \text{true} \\ \omega(Sn) & = \text{false} \end{array}$$

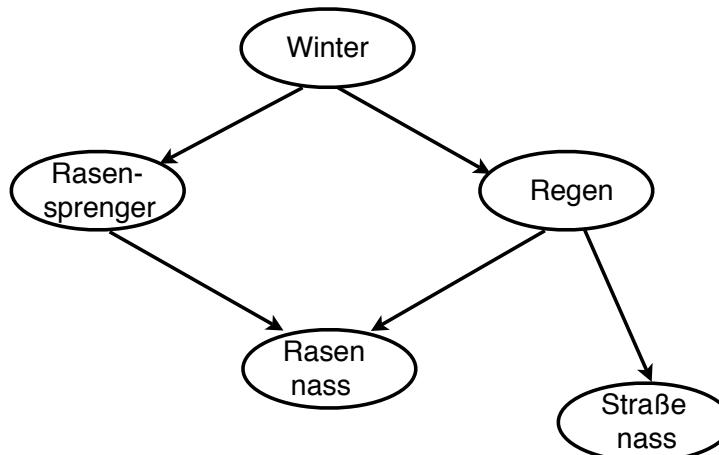
$\Theta_{Rn RS,R}$	RS	R	Rn	$\neg Rn$
	t	t	.95	.05
	t	f	.9	.1
	f	t	.8	.2
	f	f	0	1

$$\Pr(W \wedge \neg RS \wedge R) = .384$$

$$\begin{aligned}\Pr(W \wedge \neg RS \wedge R \wedge Rn) \\ = .384 \cdot .8 = .3072\end{aligned}$$

Bayes-Netze: Semantik

Die durch ein BN repräsentierte Verteilung illustrieren wir zunächst anhand eines Beispiels



Betrachte Belegung

$$\begin{aligned}\omega(W) &= \text{true} \\ \omega(RS) &= \text{false} \\ \omega(R) &= \text{true} \\ \omega(Rn) &= \text{true} \\ \omega(Sn) &= \text{false}\end{aligned}$$

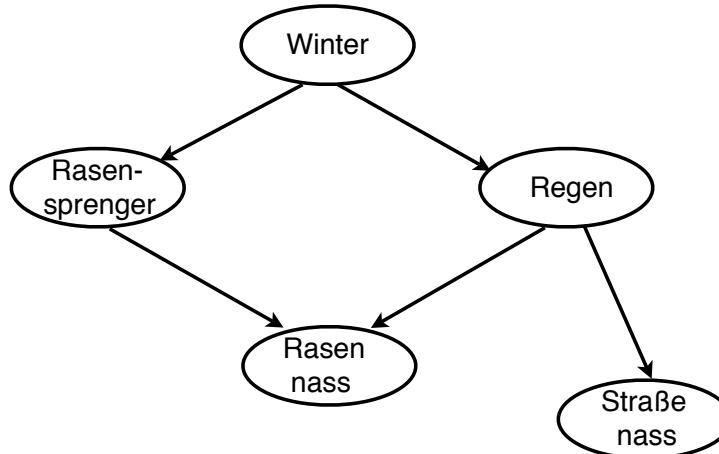
$$\Pr(W \wedge \neg RS \wedge R \wedge Rn) = .3072$$

$\Theta_{Sn R}$	R	Sn	$\neg Sn$
t	.7	.3	
f	0	1	

$$\begin{aligned}\Pr(W \wedge \neg RS \wedge R \wedge Rn \wedge Sn) &= .3072 \cdot .7 = .21504 \\ &= \Pr(\omega) !\end{aligned}$$

Bayes-Netze: Semantik

Die durch ein BN repräsentierte Verteilung illustrieren wir zunächst anhand eines Beispiels



Betrachte Belegung

$$\begin{aligned}\omega(W) &= \text{true} \\ \omega(RS) &= \text{false} \\ \omega(R) &= \text{true} \\ \omega(Rn) &= \text{true} \\ \omega(Sn) &= \text{false}\end{aligned}$$

Zusammengefasst also

$$\Pr(\omega) = \theta_{W| \cdot} \cdot \theta_{\neg RS| W} \cdot \theta_{R| W} \cdot \theta_{Rn| RS \wedge R} \cdot \theta_{\neg Sn| R}$$

Dies entspricht im wesentlichen der **sog. Kettenregel** für Wkten:

$$\Pr(\varphi_1 \wedge \cdots \wedge \varphi_n) = \Pr(\varphi_1 | \varphi_2 \wedge \cdots \wedge \varphi_n) \Pr(\varphi_2 | \varphi_3 \wedge \cdots \wedge \varphi_n) \cdots \Pr(\alpha_n).$$

Bayes-Netze: Semantik

Formal definiert man die von einem BN repräsentierte Belegung völlig analog zu vorigem Beispiel

Definition Verteilung eines Bayes-Netzes

BN $N = (G, \Theta)$ mit Variablen x_1, \dots, x_n repräsentiert Verteilung \Pr_N :
für jede Belegung $\omega = \{x_i \mapsto v_i \mid 1 \leq i \leq n\}$,

$$\Pr_N(\omega) = \prod_{i=1..n} \theta_{x_i=v_i \mid \omega/\text{Parents}(x_i)}$$

mit ω/X Einschränkung von ω auf die Variablen aus der Menge X .

Vergleiche mit

$$\Pr(\omega) = \theta_{W|} \cdot \theta_{\neg RS|W} \cdot \theta_{R|W} \cdot \theta_{Rn|RS \wedge R} \cdot \theta_{\neg Sn|R}$$

Das BN N stellt also eine **Faktorisierung** der Verteilung \Pr_N dar.



Bayes-Netze: Semantik

Die Belegung \Pr_N verhält sich wie erwartet (Beweis als Aufgabe):

Lemma

(V1) \Pr_N erfüllt alle Unabhängigkeiten in $\text{Markov}(G)$

(V2) \Pr_N erfüllt Θ in folgendem Sinne:

jedes $\theta_{x=v|\omega}$ ist die konditionale Wkt für $x = v$ gegeben φ_ω , also:

$$\Pr(x = v | \varphi_\omega) = \theta_{x=v|\omega}$$

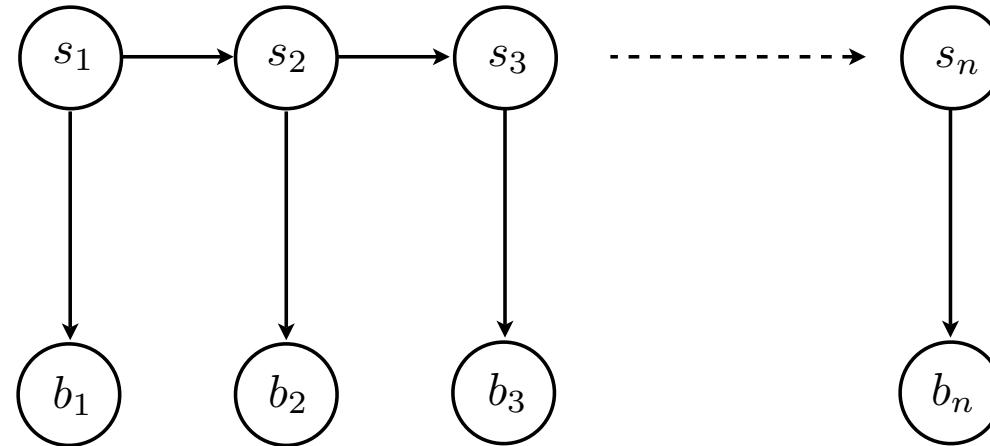
Wir werden später sogar zeigen:

\Pr_N ist die **einige** Belegung, die (V1) und (V2) erfüllt!



Bayes-Netze: Semantik

KWTs im Hidden Markov Model mit m Zuständen und m Sensorwerten

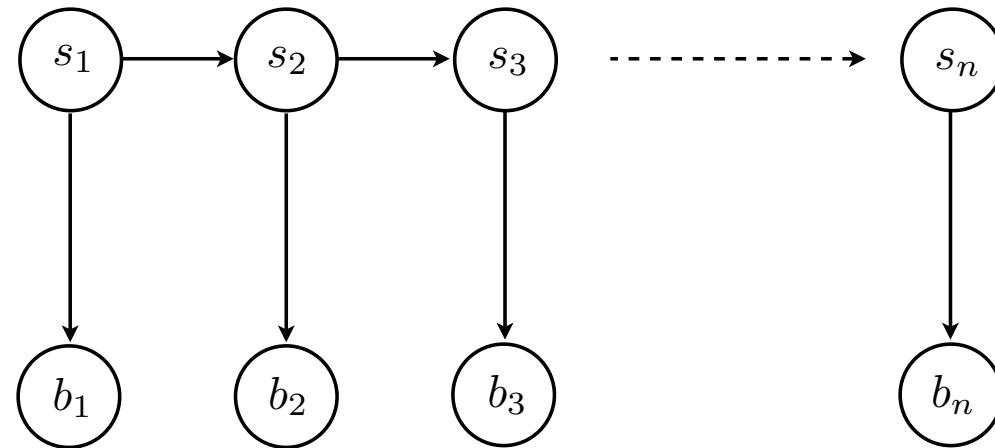


Die KWT für s_1 besteht aus einer einzelnen Verteilung:

$s_1 = 1$	$s_1 = 2$	\dots	$s_1 = m$
.1	.28	\dots	.4

Bayes-Netze: Semantik

KWTs im Hidden Markov Model mit m Zuständen und m Sensorwerten

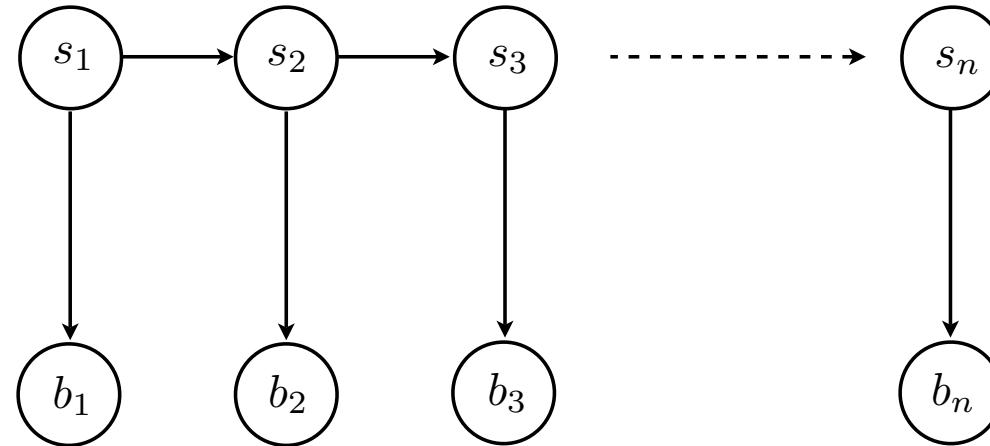


Die KWTen für s_2, \dots, s_n haben m^2 Einträge und sind alle identisch

Wert s_{i-1}	$s_i = 1$	\dots	$s_i = m$
1	.21	\dots	.05
\vdots	\vdots	\vdots	\vdots
m	0	\dots	1

Bayes-Netze: Semantik

KWTs im Hidden Markov Model mit m Zuständen und m Sensorwerten



Die KWTen für b_1, \dots, b_n haben m^2 Einträge und sind alle identisch

Wert s_i	$b_i = 1$	\dots	$b_i = m$
1	.9	\dots	.05
\vdots	\vdots	\vdots	\vdots
m	.02	\dots	.91

Bayes-Netze

Kapitel 1.3: Graphoid Axiome



MathTattoos
mathtattoos.com



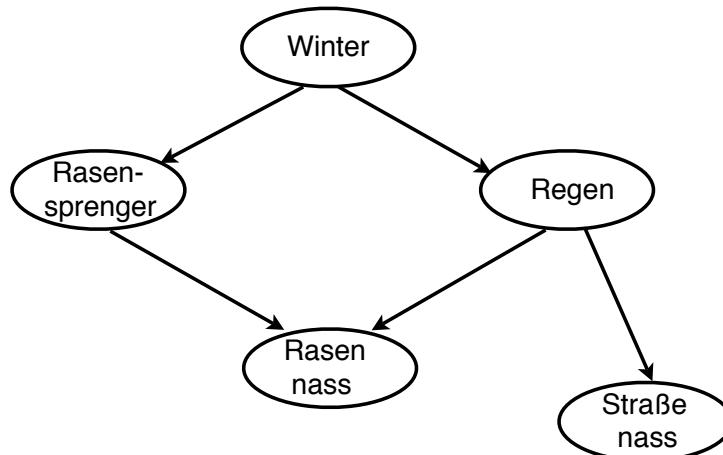
Unabhängigkeit

Unabhängigkeit zentral in Bayes-Netzen / Faktorisierungen von Verteilungen

Wir wissen bereits:

Für $N = (G, \Theta)$ erfüllt \Pr_N alle Unabhängigkeiten in $\text{Markov}(G)$.

Markov(G) sind jedoch keineswegs die **einzig**en Unabhängigkeiten in \Pr_N :



In $\text{Markov}(G)$:

$I(\text{Straßenass}, \text{Regen}, \{\text{Winter}, \text{Rasensprenger}, \text{Rasennass}\})$

dann aber auch

$I(\text{Straßenass}, \text{Regen}, \text{Winter})$

und

$I(\text{Winter}, \text{Regen}, \text{Straßenass})$

nicht in $\text{Markov}(G)$

Graphoid Axiome

Frage also: Welche Unabhängigkeiten gelten (noch) in Pr_N ?

Die **Graphoid Axiome** beschreiben, wie sich aus einer Menge konditionaler Unabhängigkeiten weitere konditionale Unabhängigkeiten ergeben

Axiomschemata I: Symmetrie

Lemma

Für alle Verteilungen Pr gilt: wenn $I_{\text{Pr}}(X, Z, Y)$, dann $I_{\text{Pr}}(Y, Z, X)$.

Ergibt sich direkt aus alternativer Def. von Unabhängigkeit:

$$\text{Pr}(\varphi \wedge \psi | \vartheta) = \text{Pr}(\varphi | \vartheta) \cdot \text{Pr}(\psi | \vartheta)$$



Graphoid Axiome

Axiomschema II: Dekomposition

Lemma

Für alle Pr gilt: wenn $I_{\text{Pr}}(X, Z, Y)$ und $Y' \subseteq Y$, dann $I_{\text{Pr}}(X, Z, Y')$

Beweis: Übung

Lemma

Pr_N ist die einzige Belegung, die folgende Bedingungen erfüllt:

(V1) Pr_N erfüllt alle Unabhängigkeiten in $\text{Markov}(G)$

(V2) Pr_N erfüllt Θ in folgendem Sinne:

jedes $\theta_{x=v|\omega}$ ist die konditionale Wkt für $x = v$ gegeben φ_ω , also:

$$\text{Pr}(x = v | \varphi_\omega) = \theta_{x=v|\omega}$$



Graphoid Axiome

Axiomschema III: Schwache Vereinigung

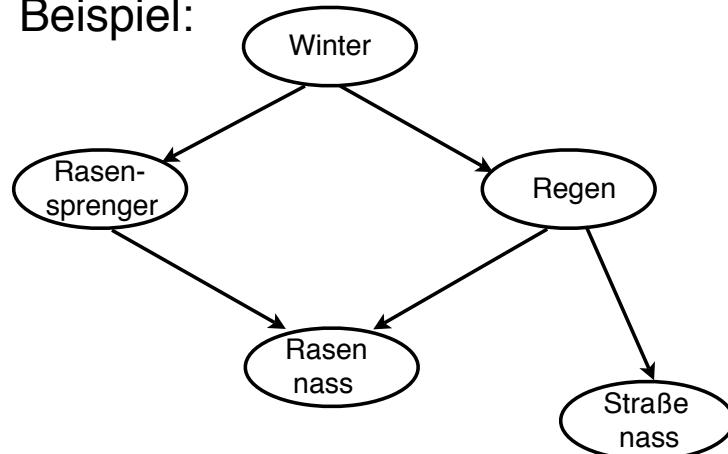
Lemma

Für alle \Pr gilt: wenn $I_{\Pr}(X, Z, Y \cup W)$, dann $I_{\Pr}(X, Z \cup Y, W)$

Intuitiv:

wenn $Y \cup W$ nicht relevant für X ist und wir die Werte der für Y “lernen”,
dann wird W dadurch nicht relevant

Beispiel:



In $\text{Markov}(G)$:

$I(\text{Straßenass}, \text{Regen},$
 $\{\text{Winter}, \text{Rasensprenger}, \text{Rasennass}\})$

mit schwacher Vereinigung auch

$I(\text{Straßenass}, \{\text{Regen}, \text{Winter}\},$
 $\{\text{Rasensprenger}, \text{Rasennass}\})$

Graphoid Axiome

Axiomschema IV: Kontraktion

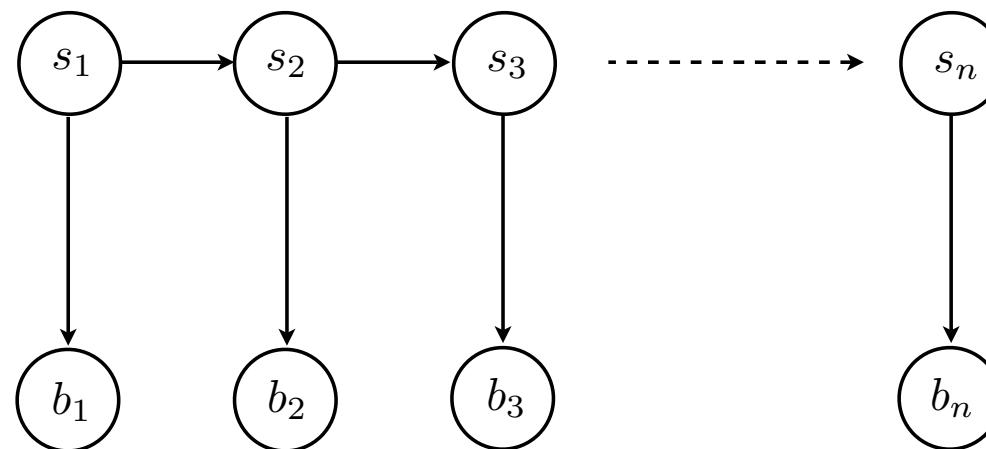
Lemma

Für alle Pr gilt: wenn $I_{Pr}(X, Z, Y)$ und $I_{Pr}(X, Z \cup Y, W)$, dann $I_{Pr}(X, Z, Y \cup W)$

Intuitiv:

wenn wir die Werte der irrelevanten Variablen Y lernen und W danach irrelevant ist, dann war vorher bereits $Y \cup W$ irrelevant

Beispiel:



Graphoid Axiome

Axiomschema V: Schnitt

Lemma

Für alle **positiven** Pr (d.h. $\Pr(\omega) > 0$ für alle ω) gilt:

wenn $I_{\Pr}(X, Z \cup W, Y)$ und $I_{\Pr}(X, Z \cup Y, W)$, dann $I_{\Pr}(X, Z, Y \cup W)$

Intuitiv:

wenn Y nach lernen von W irrelevant ist und umgekehrt, dann $Y \cup W$ irrelevant

Positive Verteilungen sind

- nicht adäquat für **streng logische** Variablenzusammenhänge
wie $x \rightarrow y$, $x_1 \wedge x_2 \rightarrow \neg y$, $x_1 \vee x_2$
- für typische BN-Anwendungen aber durchaus realistisch

Das Schnitt Axiom ist in nicht-positiven Verteilungen nicht erfüllt



Graphoid Axiome

- Liste der Graphoid Axiome:
- I Symmetrie
 - II Dekomposition
 - III Schwache Vereinigung
 - IV Kontraktion
 - (V) Schnitt - nur für **positive** Verteilungen

Manchmal wird noch das *Trivialitätsaxiom* $I_{\text{Pr}}(X, Z, \emptyset)$ hinzugenommen.

Die Graphoid Axiome sind **nicht** vollständig im folgenden Sinn:

Wenn jede Verteilung Pr , die Menge M von kond. Unabhängigkeiten erfüllt, auch $I(X, Z, Y)$ erfüllt, dann lässt sich $I(X, Z, Y)$ aus M mittels der Graphoid Axiome herleiten.

Man kann zeigen, dass keine endliche Axiomatisierung existiert mit Axiomen der Form $I(X_1, Z_1, Y_2) \wedge \dots \wedge I(X_n, Z_n, Y_n) \implies I(X, Z, Y)$

Bayes-Netze

Kapitel 1.4: d-Separation



d-Separation

Ziel:

Unabhängigkeiten in einem BN in **grafischer Weise** charakterisieren und **effiziente Algorithmen** für folgendes Problem finden:

Gegeben BN N und $I(X, Z, Y)$,
entscheide ob “ $I(X, Z, Y)$ Unabhängigkeit in N ist”.

werden wir später präzise machen

Grundidee:

$I(X, Z, Y)$ gilt in N wenn **alle Pfade** zwischen $x \in X$ und $y \in Y$ in geeigneter Weise **durch Knoten aus Z “unterbrochen”** sind.

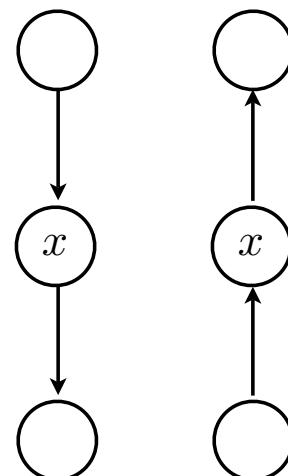


d-Separation

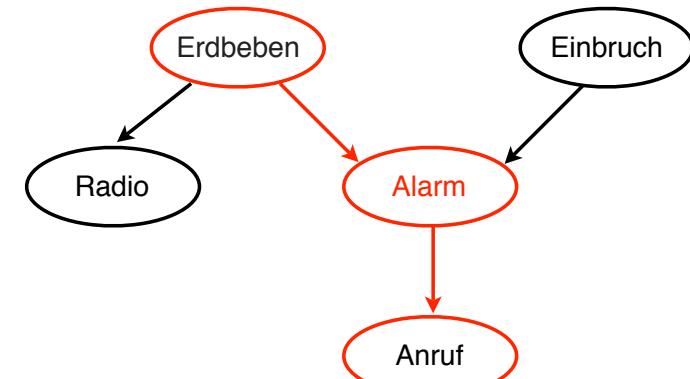
Die Knoten auf dem Pfad stellt man sich am besten als **Ventile** vor



Es gibt drei Arten von Ventilen:

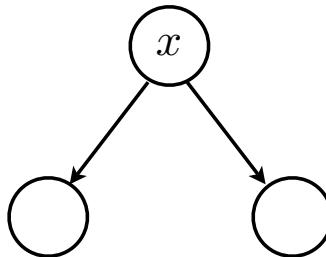


Sequentielles Ventil
Geschlossen wenn
 $x \in Z$



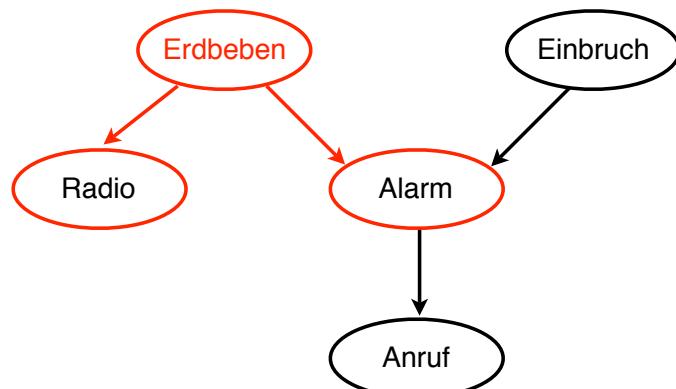
Erdbeben und Anruf unabhängig
gdw Wert von Alarm bekannt

d-Separation



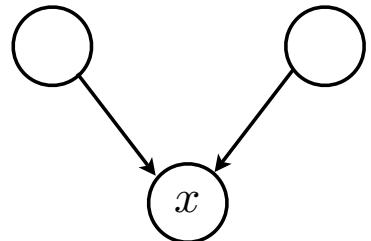
Divergentes Ventil

Geschlossen wenn $x \in Z$



1. Wert von Erdbeben bekannt
⇒ Radio und Alarm unabhängig
2. Wert von Erdbeben unbekannt
⇒ z.B. Alarm erhöht Wkt einer Radionachricht über Erdbeben

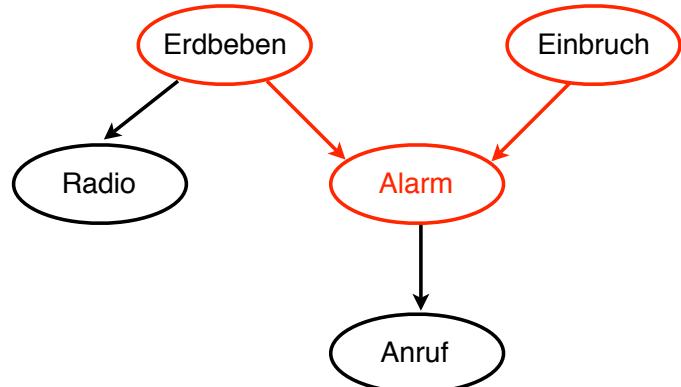
d-Separation



Konvergentes Ventil

Geschlossen wenn $x \notin Z$

und $\text{Descendants}(x) \cap Z = \emptyset$

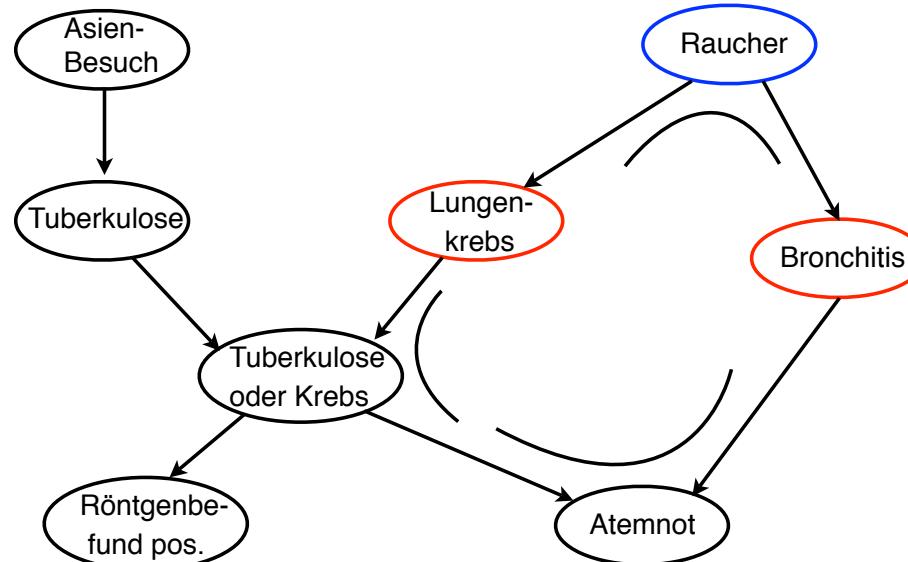


1. Wert von Alarm und Anruf unbekannt
⇒ Erdbeben und Einbruch unabhängig
2. Wert von z.B. Alarm bekannt
⇒ Erdbeben verringert Wkt von Einbruch

d-Separation

Definition d-separiert

Seien X, Y, Z disjunkte Knotenmengen in DAG G . X und Y sind *d-separiert durch Z* , geschrieben $dsep_G(X, Z, Y)$, wenn auf jedem Pfad von $x \in X$ nach $y \in Y$ ein durch Z geschlossenes Ventil liegt. Der Pfad heißt dann *Z-blockiert*.



$dsep_G(\text{Bronchitis}, \text{Raucher}, \text{Lungenkrebs}) ?$

d-Separation

D-Separation kann verwendet werden, um Unabhängigkeiten in BNen zu finden:

Theorem (Soundness)

Für alle BN $N = (G, \Theta)$ und alle disjunkten Knotenmengen X, Y, Z gilt:
 $dsep_G(X, Z, Y)$ impliziert $I_{Pr_N}(X, Z, Y)$.

Den (nicht unsubtilen) Beweis lassen wir weg: wenn $desg_G(X, Z, Y)$, dann $I_{Pr_N}(X, Z, Y)$ aus den Graphoid Axiomen herleitbar.

Folgende naive Version von Vollständigkeit gilt **offensichtlich nicht**:

Für alle BN $N = (G, \Theta)$ und alle disjunkten Knotenmengen X, Y, Z gilt:
 $I_{Pr_N}(X, Z, Y)$ impliziert $dsep_G(X, Z, Y)$.



d-Separation

Es gilt aber Vollständigkeit in folgendem schwächeren Sinne:

Theorem (Vollständigkeit)

Für jeden DAG G gibt es KWTs Θ so dass für $N = (G, \Theta)$ gilt:

$I_{\Pr_N}(X, Z, Y)$ impliziert $dsep_G(X, Z, Y)$ für alle disjunkten X, Y, Z .

Es folgt, dass man d-Separation nicht verbessern kann: kein nur auf G beruhender Test kann mehr Unabhängigkeiten herleiten.

Auch diesen Beweis lassen wir weg.

Naives Anwenden von d-Separierung erfordert das Prüfen von (schlimmstenfalls) 2^n Pfaden. Geht es auch besser?



d-Separation

Theorem

$dsep_G(X, Z, Y)$ gdw. es keinen Pfad zwischen X und Y im Graph G' gibt, der aus G wie folgt entsteht:

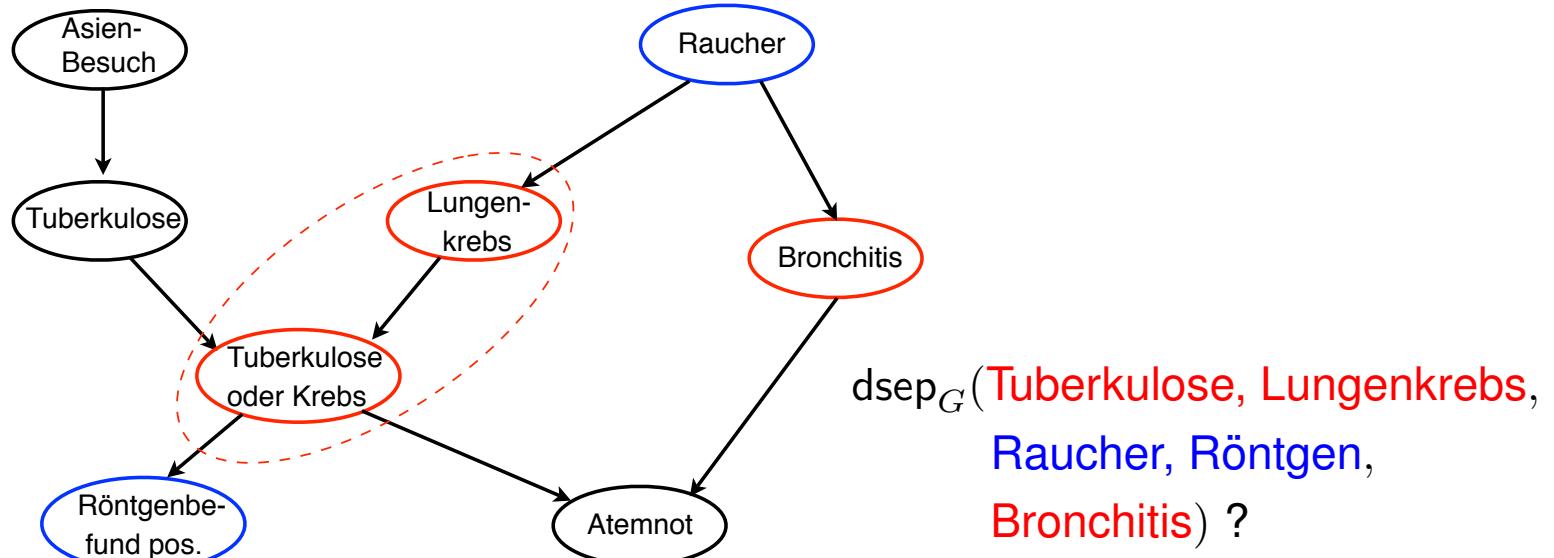
- entferne alle Blätter, die nicht zu $X \cup Y \cup Z$ gehören;
wiederhole diesen Schritt erschöpfend;
- lösche alle Kanten, die an Knoten in Z beginnen.

d-Separation

Theorem

$dsep_G(X, Z, Y)$ gdw. es keinen Pfad zwischen X und Y im Graph G' gibt, der aus G wie folgt entsteht:

- entferne alle Blätter, die nicht zu $X \cup Y \cup Z$ gehören;
wiederhole diesen Schritt erschöpfend;
- lösche alle Kanten, die an Knoten in Z beginnen.



d-Separation

Theorem

$dsep_G(X, Z, Y)$ gdw. es keinen Pfad zwischen X und Y im Graph G' gibt, der aus G wie folgt entsteht:

- entferne alle Blätter, die nicht zu $X \cup Y \cup Z$ gehören;
wiederhole diesen Schritt erschöpfend;
- lösche alle Kanten, die an Knoten in Z beginnen.



Komplexität:

- Erreichbarkeit in Graphen ist in **Linearzeit** entscheidbar
- Die entsprechenden Algorithmen können leicht angepasst werden,
um auch **dsep** selbst in Linearzeit zu entscheiden.

Übersicht Vorlesung

- Motivation und Grundlagen
- Kapitel 1: Bayes-Netze
- Kapitel 2: Schlussfolgerungsmechanismen
- Kapitel 3: Komplexität und Approximation
- Kapitel 4: Maschinelles Lernen